

BỘ KHOA HỌC VÀ CÔNG NGHỆ
HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG



BÁO CÁO THỰC TẬP CƠ SỞ

**Đề tài: Tìm hiểu và ứng dụng mạng nơ-ron tích
chập (CNN) trong bài toán phân loại hình ảnh
giống cây bệnh.**

Giảng viên hướng dẫn	: ThS. Bùi Văn Kiên
Họ và tên sinh viên	: Khổng Thị Thuỳ Linh
Mã sinh viên	: B23DCCN483
Lớp	: D23CQCN07-B
Nhóm	: 25

Hà Nội – 2026

Table of Contents

I.	<i>Phân lý thuyết</i>	3
1.1.	Giới thiệu Deep Learning	3
1.2.	Mạng nơ-ron nhân tạo	5
1.3.	Cấu trúc CNN	9
1.3.1.	Convolutional Layer	9
1.3.2.	Pooling layer	10
1.3.3.	Fully Connected Layer	11
II.	<i>Tài liệu tham khảo</i>	14

I. Phần lý thuyết

1.1. Giới thiệu Deep Learning

a. Quá trình hình thành

Trước khi tìm hiểu về quá trình hình thành của Deep Learning, ta cần nắm rõ các thuật ngữ quan trọng: *Artificial Intelligence (AI)* và *Machine Learning (ML)*

** Artificial Intelligence (AI):* hay còn được gọi là trí tuệ nhân tạo, được định nghĩa là **bản sao của trí tuệ con người** trong máy tính.

** Machine Learning (ML):* hay còn được gọi là học máy, ML hướng đến **khả năng của một cái máy để học cách sử dụng lượng lớn tập dữ liệu (dataset)**, thay vì các quy tắc đã được đặt sẵn cho nó.

Vd: Trong lập trình truyền thống, con người sẽ viết luật sẵn cho máy để máy xử lý:

- Máy chỉ nhận số chẵn: Nếu số chia hết cho 2 → số chẵn → nhận. Ở đây, con người nghĩ luật và máy chỉ việc làm theo.

Nhưng Machine Learning thì khác, với ML ta không đưa luật chi tiết, mà đưa cho máy rất nhiều dữ liệu (dataset) kèm theo với đáp án đúng. Khi đó, máy sẽ tự suy ra quy luật và tự học cách đưa ra dự đoán. Cách học này lợi dụng sức mạnh xử lý của máy tính hiện đại, những chiếc máy có thể xử lý được lượng lớn dữ liệu.

Supervised Learning và Unsupervised Learning.

Supervised Learning (Học có giám sát):* **bao gồm việc sử dụng các tập dữ liệu có dán nhãn (labelled dataset) mà có các đầu vào và đầu ra được dự đoán. Nói cách khác, là học bằng dữ liệu có sẵn đáp án đúng.

Vd:

Ảnh (Input)	Label
Ảnh con mèo	“Mèo”
Ảnh con cún	“Cún”

Máy học rất nhiều cặp I/O như vậy, sau khi học xong, gặp ảnh mới chưa từng học → nó tự đoán.

Unsupervised Learning (Học không có giám sát):* Là **nhiệm vụ của học máy để sử dụng các tập dữ liệu không có cấu trúc cụ thể. Khi đó, ta đưa cho máy tập dữ liệu nhưng không có đáp án đúng (không có label), máy phải tự tìm cấu trúc, nhận ra quy luật và phân nhóm dữ liệu.

Vd: Khi người dùng đưa cho máy 10.000 ảnh đủ loại con vật, nhưng không cho đáp án. Máy sẽ tự phân loại những nhóm ảnh có đặc điểm giống nhau, điểm chung.

→ Thay vì “Đây là mèo”, máy sẽ chạy: “Mấy bức ảnh này trông giống nhau, gom một nhóm”

b. Cách Deep Learning hoạt động


**Deep learning là gì?*

Deep Learning là một nhánh của Machine Learning dùng mạng nơ-ron nhân tạo nhiều lớp. (deep = nhiều tầng xử lý). Nó cho phép chúng ta huấn luyện một AI có thể dự đoán được các output dựa trên một tập các đầu vào. Cả hai phương pháp có giám sát và không giám sát đều có thể sử dụng để huấn luyện.

Nó được lấy cảm hứng từ não của con người trong việc xử lý thông tin.

**Deep learning hoạt động như thế nào?*

Do lấy cảm hứng từ bộ não của con người, bộ não của AI cũng có các nơ-ron. Deep learning hoạt động qua các lớp (layer) trong mạng nơ-ron.



**Nguồn ảnh: <https://viblo.asia/p/gioi-thieu-ve-deep-learning-deep-learning-hoat-dong-nhu-the-nao-3Q75w2nDlWb>*

Như trên hình ảnh minh họa, bên trong mỗi lớp là rất nhiều nơ-ron, chúng được biểu diễn bằng các vòng tròn.

1. Input layer

Đây là lớp nhận dữ liệu đầu vào, với CNN, đầu vào là ảnh (pixel).

2. Các Hidden layer

Các lớp ẩn sẽ xử lý dần dần, mỗi lớp sẽ học một đặc trưng khác nhau.

Vd:

Lớp (layer)	Mục tiêu học
Layer 1	Đường thẳng, cạnh màu
Layer 2	Hình dạng, hoa văn


Layer 3	Bộ phận vật thể (mắt, tai, chân)
Layer 4	Nhận diện đối tượng hoàn chỉnh

Càng vào lớp sâu → Càng hiểu đối tượng rõ hơn.

3. Output layer

Nếu là bài toán có giám sát, sau khi đưa ra output layer mô hình sẽ so sánh với đáp án đúng và tính toán sai số. Cuối cùng là bước sử dụng thuật toán để điều chỉnh lại các trọng số để lần sau đoán chính xác hơn.

Tổng kết: Deep Learning học theo mô hình sau:



1.2. Mạng nơ-ron nhân tạo

Vậy một nơ-ron nhân tạo thực sự làm gì để máy móc có thể tính toán được kết quả để truyền sang lớp sâu hơn? Để tìm hiểu điều đó, trước hết chúng ta cần hiểu rõ về khái niệm Mạng nơ-ron nhân tạo.

1.2.1. Khái niệm mạng nơ-ron nhân tạo

Mạng nơ-ron nhân tạo (Neural Network) là một mô hình học máy được thiết kế theo dạng mô phỏng các tế bào thần kinh bên trong não bộ con người trong việc truyền tín hiệu và xử lý thông tin.

1.2.2. Cấu trúc cơ bản của mạng nơ-ron nhân tạo

Cấu trúc của mạng nơ-ron nhân tạo gồm có 3 lớp cơ bản: *Input Layer*, *Hidden Layer* và *Output Layer*. Cấu trúc này khá giống với cấu trúc của Deep Learning, vì Deep Learning không phải mô hình khác hoàn toàn, mà là phiên bản mạng nơ-ron nhân tạo nâng cấp hơn, có nhiều lớp ẩn hơn.

- **Input layer:** Đây là lớp nằm bên trái của mạng, nơi dữ liệu đi vào mạng nơ-ron.
- **Hidden layer:** Nằm giữa input layer và output layer, nơi mạng nơ-ron thực sự học và xử lý thông tin. → Đây là lúc mạng học các mẫu.

- **Output layer:** Đây là lớp nằm phía bên phải và là lớp cuối cùng của mạng nơ-ron, nơi mô hình đưa ra kết quả dự đoán cuối cùng dựa trên quá trình xử lý các lớp trước đó.

Ngoài ra, để tạo thành một mạng nơ-ron nhân tạo còn cần có các thành phần cơ bản sau:

- **Tế bào thần kinh (Neurons):** Đây là các đơn vị tính toán cơ bản trong mạng nơ-ron, tương tự như các tế bào thần kinh trong não người. Mỗi nơ-ron nhận tín hiệu đầu vào (các giá trị số), áp dụng trọng số và độ lệch, sau đó sử dụng một hàm kích hoạt để tính toán đầu ra. Kết quả này được truyền đến các nơ-ron khác trong mạng để tiếp tục xử lý.
- **Kết nối (Connections):** Các kết nối giữa các nơ-ron là các liên kết truyền tải thông tin từ nơ-ron này sang nơ-ron khác. Mỗi kết nối có một giá trị trọng số (weight) để xác định mức độ ảnh hưởng của nó đối với đầu ra của nơ-ron nhận thông tin.
- **Trọng số và Độ lệch (Weights and Biases):** Trọng số là tham số điều chỉnh độ mạnh yếu của các kết nối giữa các nơ-ron, quyết định mức độ ảnh hưởng của một đầu vào đến kết quả tính toán của nơ-ron. Còn độ lệch (bias) giúp điều chỉnh các đầu vào sao cho mạng nơ-ron có thể học chính xác hơn, đặc biệt khi đầu vào không có giá trị rõ ràng.
- **Truyền tiến và truyền ngược (Forward & Backward Propagation):** Đây là các cơ chế giúp truyền tải và xử lý dữ liệu qua các lớp nơ-ron.
- **Quy tắc học (Learning Rule):** Để mạng nơ-ron học được từ dữ liệu, quy tắc học đóng vai trò giúp mạng điều chỉnh trọng số và độ lệch qua thời gian, từ đó cải thiện độ chính xác của mạng.

1.2.3. Nguyên lý hoạt động của mạng nơ-ron nhân tạo

***Forward Propagation (Truyền tiến)**

Khi dữ liệu được đưa vào mạng, nó sẽ di chuyển qua các lớp của mạng nơ-ron từ lớp đầu vào đến lớp đầu ra. Quá trình này được gọi là truyền dữ liệu theo chiều tiến (forward propagation). Trong giai đoạn này, mạng nơ-ron nhân tạo hoạt động như sau:

- **Biến đổi tuyến tính:** Mỗi nơ-ron trong một lớp nhận đầu vào, sau đó nhân các giá trị này với các trọng số (weight) của các kết nối. Các giá trị này được cộng lại với nhau và một độ lệch (bias) được thêm vào. Cách tính này có thể được diễn tả dưới dạng toán học như sau:

$$z = w_1 * 1 + w_2 * 2 + \dots + w_n * n + b$$

(Trong đó w là trọng số, x là đầu vào và b là độ lệch)

Hàm kích hoạt: Kết quả của phép biến đổi tuyến tính (ký hiệu là z) sau đó được đưa qua một hàm kích hoạt. Hàm kích hoạt có vai trò quan trọng trong việc giới thiệu tính phi tuyến vào hệ thống giúp mạng nơ-ron học và nhận diện các mẫu phức tạp hơn. Một số hàm kích hoạt phổ biến gồm ReLU, sigmoid, tanh.

***Backward propagation (Truyền ngược)**

Sau khi quá trình truyền tiến hoàn tất, mạng sẽ đánh giá độ chính xác của kết quả bằng một hàm mất mát (loss function). Hàm mất mát sẽ đo lường sự chênh lệch giữa kết quả dự đoán của mạng và kết quả thực tế.

Quá trình truyền ngược giúp tối ưu hoá mạng nơ-ron thông qua các bước:

- Tính toán hàm mất mát: Sau khi forward propagation (truyền tiến) xong, mạng có kết quả dự đoán, hàm mất mát sẽ trả lời cho câu hỏi: **kết quả đã sai bao nhiêu?**
 - Sai ít $\rightarrow$ loss nhỏ
 - Sai nhiều $\rightarrow$ loss lớn
 - VD: Bài toán hồi quy $\rightarrow$ Dùng MSE, bài toán phân loại $\rightarrow$ dùng Cross-Entropy.
- Tính toán Gradient (độ dốc): Sau khi biết sai bao nhiêu, mạng cần biết: **Phải chỉnh trọng số theo hướng nào để giảm lỗi?** Gradient chính là: hướng + mức độ thay đổi của loss khi thay đổi từng tham số. Mạng dùng quy tắc chuỗi (chain rule) để:
 - Lan truyền lỗi từ lớp đầu ra
 - Ngược về các lớp trước
 - Vì vậy gọi là backpropagation (truyền ngược)
 - Hiểu đơn giản, tính Gradient chính là tìm xem mỗi trọng số góp phần gây lỗi bao nhiêu, từ đó tìm ra hướng chỉnh
- Cập nhật trọng số: Sau khi biết hướng chỉnh, mạng điều chỉnh trọng số để giảm lỗi
 - Công thức ý tưởng: trọng số mới = trọng số cũ - learning rate * gradient
 - Gradient: hướng cần đi
 - Learning rate: bước đi dài hay ngắn

***Lặp lại quá trình (Iteration)**

Quá trình truyền dữ liệu theo chiều tiến, tính toán hàm mất mát, truyền ngược dữ liệu và cập nhật trọng số sẽ được lặp đi lặp lại qua nhiều vòng (iterations) trên toàn bộ tập dữ liệu.

Qua mỗi vòng lặp, hàm mất mát sẽ giảm dần và dự đoán của mạng nơ-ron ngày càng chính xác hơn.

1.2.4. Các phương pháp học của mạng nơ-ron nhân tạo

- Học có giám sát (Supervised Learning)
- Học không giám sát (Unsupervised Learning)

- Học tăng cường (Reinforcement Learning): Học tăng cường là phương pháp mà mạng nơ-ron học bằng cách thử và sai, giống như cách con người và động vật học từ trải nghiệm
 - VD: Hãy tưởng tượng khi bạn đang chơi một trò chơi
 - Khi bạn làm đúng → bạn được điểm thưởng (reward)
 - Khi bạn làm sai → bạn bị phạt (penalty)
 - Mạng sẽ cố gắng tìm ra chiến lược tối ưu giúp tối đa hoá tổng phần thưởng trong suốt quá trình học.

1.2.5. Ứng dụng của mạng nơ-ron nhân tạo đối với đề tài bài toán phân loại hình ảnh

1. Nhận diện khuôn mặt

- Mở khoá điện thoại bằng khuôn mặt
- Xác thực danh tính trong hệ thống bảo mật
- Gắn thẻ người trong ảnh
- VD: Hệ thống face ID, camera an ninh

2. Chẩn đoán y khoa từ ảnh

- Phân loại ảnh X-quang (có bệnh/ không bệnh)
- Phát hiện khối u trong ảnh MRI hoặc CT
- Giúp bác sĩ hỗ trợ chẩn đoán nhanh và chính xác hơn

3. Xe tự lái

- Nhận diện biển báo giao thông
- Phân loại vật thể: người đi bộ, xe cộ, làn đường
- Là một thành phần quan trọng trong hệ thống lái tự động

4. Kiểm tra chất lượng sản phẩm

- Phát hiện lỗi trên dây chuyền sản xuất
- Phân loại sản phẩm đạt/ không đạt
- Ứng dụng nhiều trong sản xuất công nghiệp

5. Tìm kiếm và gợi ý hình ảnh

- Tìm ảnh tương tự trong thư viện
- Gợi ý sản phẩm theo hình ảnh
- Dùng trong thương mại điện tử và mạng xã hội

6. Phân loại nội dung

- Phát hiện nội dung không phù hợp
- Lọc ảnh spam hoặc ảnh nhạy cảm
- Giúp kiểm duyệt nội dung tự động

1.2.6. Thách thức và hạn chế của mạng nơ-ron nhân tạo.

- **Thiếu quy tắc cấu trúc mạng:** Không có quy tắc cụ thể để xác định cấu trúc mạng, việc chọn kiến trúc phù hợp phụ thuộc vào thử nghiệm và kinh nghiệm
- **Tốn kém tài nguyên tính toán:** Huấn luyện mạng nơ-ron yêu cầu tài nguyên tính toán lớn, điều này có thể trở thành rào cản đối với các tổ chức có nguồn lực hạn chế.

- **Phụ thuộc vào phần cứng:** Mạng nơ-ron cần bộ xử lý có khả năng xử lý song song, khiến việc triển khai phụ thuộc vào phần cứng đặc biệt như GPU
- **Chuyển đổi dữ liệu thành số:** Mạng nơ-ron chỉ làm việc với dữ liệu dạng số, yêu cầu quá trình chuyển đổi trước khi xử lý.
- **Kết quả không chính xác:** Nếu huấn luyện không đúng, mạng nơ-ron có thể đưa ra kết quả không chính xác hoặc thiếu sót .
- **Hiện tượng overfitting:** Mạng nơ-ron dễ bị overfitting khi huấn luyện với dữ liệu nhỏ, làm giảm khả năng tổng quát hoá khi áp dụng cho dữ liệu mới.

1.3. Cấu trúc CNN

Convolution Neural Network (CNN) là một loại mô hình trong lĩnh vực Deep Learning được thiết kế đặc biệt để xử lý ảnh. Nói một cách đơn giản, CNN là một mạng nơ-ron có khả năng “nhìn” và hiểu hình ảnh.

Để chỉ ra điểm đặc biệt của CNN, trước hết ta cùng lục lại về các phương pháp cũ: để máy tính nhận diện hình ảnh, con người phải:

- Tự viết thuật toán để tìm cạnh
- Tìm góc
- Tìm màu sắc
- Tìm hình dạng

→ Việc này gọi là trích xuất đặc trưng thủ công.

CNN làm theo một cách hoàn toàn khác, CNN tự học đặc trưng từ dữ liệu. Ví dụ với bài toán phân loại giống cây bệnh, khi huấn luyện CNN với hình ảnh lá cây

- Các lớp đầu sẽ học: cạnh lá, đường gân lá
- Các lớp sau sẽ học hình dạng lá, đốm bệnh
- Các lớp sâu hơn sẽ hiểu: loại bệnh của cây

Nói về cách hoạt động của CNN, CNN sử dụng phép toán gọi là:

Convolution (tích chập).

Hiểu một cách đơn giản về Convolution:

- Một bộ lọc nhỏ (filter/kernel) sẽ quét qua ảnh
- Bộ lọc này giúp phát hiện đặc trưng như: cạnh, góc, texture

Để tìm hiểu về CNN, trước hết chúng ta tìm hiểu về các lớp cơ bản và nguyên lý hoạt động của Convolutional Neural Networks.

1.3.1. Convolutional Layer

Convolutional layer là lớp quan trọng nhất trong CNN. Nhiệm vụ của lớp này là: trích xuất đặc trưng (features) từ ảnh

Ví dụ với ảnh chiếc lá, CNN có thể phát hiện:

- Cạnh của lá
- Đường gân
- Đốm bệnh
- Hình dạng lá

Lớp Convolution này sử dụng một bộ lọc (kernel) để quét qua từng vùng nhỏ của hình ảnh và thực hiện phép nhân tích chập (convolution) giữa các giá trị pixel với trọng số của bộ lọc.

Kernel là một ma trận nhỏ, ví dụ về kernel 3x3:

$$\begin{bmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{bmatrix}$$

Kernel sẽ quét qua toàn bộ ảnh, mỗi lần quét:

- Lấy một vùng nhỏ của ảnh
- Nhân từng pixel với giá trị trong kernel
- Cộng lại

→ Phép toán này gọi là Convolution(tích chập)

Kết quả của quá trình này tạo thành **bản đồ đặc trưng (feature map)**, giúp mô hình phát hiện các đặc điểm như cạnh, góc, màu sắc hoặc kết cấu trong ảnh.

Feature map cho biết:

- Vị trí cạnh
- Vị trí góc
- Vị trí kết cấu

Ví dụ: Khi quét qua ảnh góc, Feature map chỉ giữ lại những đặc trưng quan trọng.

CNN thường dùng nhiều kernel khác nhau, nên sẽ tạo ra nhiều feature map.

Các tham số quan trọng của lớp tích chập bao gồm: Số lượng bộ lọc, Stride (bước di chuyển của bộ lọc) và Padding (giữ kích thước ảnh). Trong đó:

- Stride là bước di chuyển của kernel.
Ví dụ: Stride = 1, kernel di chuyển từng pixel một
Stride = 2, kernel nhảy 2 pixel
→ Stride lớn hơn thì feature map sẽ nhỏ hơn.
- Padding là việc thêm pixel vào viền ảnh. Mục đích là giữ kích thước ảnh và tránh mất thông tin ở viền ảnh.

Sau mỗi phép tích chập, Convolutional Neural Networks thường áp dụng hàm kích hoạt ReLU (Rectified Linear Unit) để loại bỏ giá trị âm, tăng tính phi tuyến và giúp mô hình học hiệu quả hơn.

Công thức : $f(x) = \max(0, x)$

Tổng kết: Convolutional layer chịu trách nhiệm trích xuất các đặc trưng từ dữ liệu đầu vào.

1.3.2. Pooling layer

Sau khi ảnh đi qua Convolutional Layer, ta thu được feature map. Lúc này kích thước feature map vẫn còn khá lớn, nên Pooling layer được sử dụng để:

- Giảm kích thước feature map
- Giảm số lượng tham số
- Tăng tốc độ tính toán

- Giảm nguy cơ overfitting

Trong CNN, pooling giống như bước nén thông tin quan trọng của ảnh.

**Cách hoạt động của pooling:*

Pooling sử dụng một cửa sổ nhỏ (2x2 hoặc 3x3) để quét qua feature map.

Thay vì giữ lại tất cả giá trị pixel, pooling chỉ giữ lại một giá trị đại diện cho vùng đó.

Ví dụ: có ma trận ban đầu (feature map) :

$$\begin{bmatrix} 4 & 2 & 1 & 3 \\ 6 & 5 & 2 & 1 \\ 7 & 3 & 4 & 2 \\ 1 & 2 & 3 & 4 \end{bmatrix}$$

Ta dùng Max Pooling 2x2, chia ma trận thành các vùng 2x2, ta có kết quả sau pooling:

$$\begin{bmatrix} 6 & 3 \\ 7 & 4 \end{bmatrix}$$

**Ta có 2 loại pooling phổ biến*

- Max Pooling: Như ví dụ ở trên, cách hoạt động của Max Pooling là chọn giá trị lớn nhất trong vùng quét. Từ đó, Max Pooling giúp **giữ lại đặc trưng mạnh nhất** và **giúp mô hình tập trung vào chi tiết nổi bật**.
→ Vì vậy Max Pooling được dùng nhiều nhất trong CNN.
- Average Pooling: Cách hoạt động là lấy giá trị trung bình của vùng quét. Từ đó **giúp tổng hợp thông tin** thay vì chỉ giữ giá trị lớn nhất như Max Pooling

**Pooling giúp tránh Overfitting*

Overfitting là hiện tượng:

- Mô hình học hoá quá kỹ dữ liệu huấn luyện
- Tuy nhiên, dự đoán kém với dữ liệu mới

Pooling giúp giảm overfitting vì:

- Giảm số lượng dữ liệu cần học
- Làm mô hình đơn giản hơn
- Giúp mô hình tổng quát tốt hơn.

1.3.3. Fully Connected Layer

Fully Connected Layer là lớp cuối cùng trong CNN với nhiệm vụ: dùng các đặc trưng đã trích xuất để đưa ra kết quả phân loại cuối cùng.

Các lớp trước (Convolution + Pooling) chỉ làm việc: tìm cạnh, tìm hình dạng, tìm đặc trưng của ảnh, Fully Connected Layer mới là lớp quyết định ảnh thuộc loại nào (phân loại ảnh)

**Fully Connected (Kết nối đầy đủ)*

Trong lớp này, mỗi nơ-ron sẽ kết nối với tất cả nơ-ron ở lớp trước

Ví dụ: Lớp trước có 100 nơ-ron → một nơ-ron ở Fully Connected sẽ nhận 100 giá trị đầu vào. Do đó gọi là “kết nối đầy đủ”

**Flattening (làm phẳng)*

Trước khi vào Fully Connected Layer, dữ liệu thường là feature map dạng ma trận, CNN sẽ biến nó thành một vector một chiều. Quá trình này gọi là Flattening.

Ví dụ: $\begin{bmatrix} 2 & 4 \\ 3 & 5 \end{bmatrix} \rightarrow [2, 4, 3, 5]$

Ma trận → chuỗi số một chiều để đưa vào mạng nơ-ron.

**Hàm kích hoạt ở lớp cuối*

Sau khi xử lý ở Fully Connected Layer, CNN sử dụng hàm kích hoạt để tính xác suất cho từng lớp. Hai hàm phổ biến

- Softmax: thường được dùng khi phân loại nhiều lớp (VD: chó, mèo, ô tô)
- Sigmoid: thường dùng khi phân loại 2 lớp (bệnh / không bệnh) hoặc multi-label classification

1.3.4. Additional layer

Ngoài các lớp chính của CNN như Convolutional Layer, Pooling Layer, Fully Connected Layer, CNN còn có một số lớp phụ giúp:

- Mô hình học tốt hơn
- Huấn luyện nhanh hơn
- Giảm lỗi khi dự đoán

**Activation Layer (lớp kích hoạt):*

Activation Layer là lớp áp dụng hàm kích hoạt phi tuyến cho các giá trị đầu vào. Với mục đích:

- Giúp mô hình học các mối quan hệ phức tạp
- Nếu không có activation, mạng chỉ giống như một phép toán tuyến tính đơn giản
- Các hàm kích hoạt phổ biến:
 - ReLU: $f(x) = \max(0, x)$
Ưu điểm: Tính toán nhanh và hiệu quả nên được dùng nhiều nhất trong CNN
 - Sigmoid: $f(x) = 1/(1 + e^{-x})$. Kết quả nằm trong khoảng $0 \rightarrow 1$
Thường dùng cho bài toán phân loại nhị phân
 - Tanh (Hyperbolic Tangent): giá trị nằm trong khoảng $-1 \rightarrow 1$.
Tanh giúp dữ liệu cân bằng quanh 0.

**Dropout Layer*

Dropout Layer là kỹ thuật giúp giảm overfitting

Cách hoạt động: Trong quá trình huấn luyện: Dropout sẽ tắt ngẫu nhiên một số nơ-ron.

→ Kết quả:

- Mô hình không phụ thuộc vào một số nơ-ron cụ thể
- Khả năng tổng quát hoá tốt hơn

**Batch Normalization Layer*

Batch Normalization là lớp chuẩn hoá dữ liệu trong mạng, giúp dữ liệu ổn định hơn và giúp mạng học nhanh hơn

Cách hoạt động: Batch Normalization:

- Lấy một batch dữ liệu
- Tính trung bình và độ lệch chuẩn
- Chuẩn hoá dữ liệu

Tác dụng:

- Giảm hiện tượng Gradient bị quá lớn hoặc quá nhỏ
- Tăng tốc quá trình huấn luyện

1.3.5. Ba thành phần quan trọng trong cấu trúc CNN

Ngoài các lớp, CNN còn có 3 cơ chế quan trọng giúp mô hình hoạt động hiệu quả:

**Local Receptive Field (Trường tiếp nhận cục bộ)*

Trong mạng nơ-ron truyền thống, **mỗi nơ-ron kết nối với tất cả pixel của ảnh**. Điều này làm: số tham số rất lớn + tính toán chậm.

Để giải quyết những khuyết điểm này, CNN chỉ nhìn một vùng nhỏ của ảnh.

Ví dụ: Với ảnh 32x32 pixel, kernel 3x3, một nơ-ron chỉ xử lý 3x3 pixel chứ không phải toàn bộ ảnh

Như vậy, với cơ chế Local Receptive Field, CNN giúp:

- Phát hiện đặc trưng theo từng khu vực nhỏ
- Giảm số tham số
- Tăng hiệu quả tính toán.

**Shared Weights (Trọng số chia sẻ)*

Trong CNN, một kernel được dùng cho toàn bộ ảnh.

Ví dụ:

Kernel phát hiện cạnh ngang:

$$\begin{bmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{bmatrix}$$

Kernel này sẽ: quét toàn bộ ảnh và phát hiện cạnh ở mọi vị trí

Như vậy, với cơ chế Shared Weights (Trọng số chia sẻ), CNN giúp :

- Giảm số lượng tham số
- Giúp mô hình nhận diện cùng một đặc trưng ở nhiều vị trí khác nhau

**Pooling layer*

Pooling có nhiệm vụ:

- Giảm kích thước feature map
- Giữ lại thông tin quan trọng

Có hai loại pooling phổ biến: Max pooling và Average pooling (đã giải thích rõ ở phần 1.3.2)

Qua 3 cơ chế kể trên, ta có thể suy ra: CNN học đặc trưng theo nhiều cấp độ. Nói một cách cụ thể hơn, điểm mạnh của CNN là học **đặc trưng từ đơn giản đến phức tạp**.

II. Tài liệu tham khảo

1. <https://viblo.asia/p/gioi-thieu-ve-deep-learning-deep-learning-hoat-dong-nhu-the-nao-3Q75w2nDIWb>
2. <https://vnptai.io/vi/blog/detail/neural-network-la-gi>
3. <https://vnptai.io/vi/blog/detail/convolutional-neural-networks-la-gi>
4. <https://www.youtube.com/watch?v=UIPmxeyRWdA>