

BỘ KHOA HỌC VÀ CÔNG NGHỆ

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG



BÁO CÁO THỰC TẬP CƠ SỞ

Đề tài: Tìm hiểu và ứng dụng mạng nơ-ron tích chập (CNN) trong bài toán phân loại hình ảnh giống cây bệnh.

Giảng viên hướng dẫn	: ThS.Bùi Văn Kiên
Họ và tên sinh viên	: Khổng Thị Thuỳ Linh
Mã sinh viên	: B23DCCN483
Lớp	: D23CQCN07-B
Nhóm	: 25

Hà Nội – 2026

Mục lục

<u>I.</u>	<u>PHẦN LÝ THUYẾT</u>	<u>3</u>
1.1.	GIỚI THIỆU DEEP LEARNING.....	4
1.2.	MẠNG NƠ-RON NHÂN TẠO.....	6
1.3.	CẤU TRÚC CNN	10
1.3.1.	CONVOLUTIONAL LAYER.....	11
1.3.2.	POOLING LAYER	12
1.3.3.	FULLY CONNECTED LAYER.....	13
<u>II.</u>	<u>PHẦN THỰC NGHIỆM</u>	<u>17</u>
2.1.	THU THẬP DATASET ẢNH.....	17
2.1.3.	XÂY DỰNG MÔ HÌNH CNN BẰNG PYTHON + TENSORFLOW/KERAS VỚI BÀI TOÁN PHÂN LOẠI GIỐNG CÂY BỆNH.....	19
2.2.	ĐÁNH GIÁ.....	24
2.2.1.	ACCURACY	24
2.2.2.	LOSS	25
2.2.3.	SỐ SÁNH VỚI MODEL CÓ SẴN (MOBILENET)	26
<u>III.</u>	<u>TÀI LIỆU THAM KHẢO</u>	<u>36</u>

Danh mục hình vẽ

Hình 1. Hình minh hoạ Deep Learning.....	5
Hình 2. Mô hình thứ tự học của Deep Learning.....	6
Hình 3. Minh hoạ cách hoạt động của Pooling layer	13
Hình 4. Cấu trúc CNN	14
Hình 5. Dataset tải về từ Kaggle.....	18
Hình 6. Xử lý phân loại dataset thành các tập training, validation, test	19
Hình 7. Code import thư viện	20
Hình 8. Code load dữ liệu train_data, val_data	20
Hình 9. Code chuẩn hoá dữ liệu	20
Hình 10. Code xây dựng mô hình CNN.....	21
Hình 11. Code compile model.....	22
Hình 12. Thuật toán Early_stopping	23
Hình 13. Train model.....	23
Hình 14. Lưu model bằng file plant_disease_model.keras	23
Hình 15. Biểu đồ Accuracy của mô hình tự xây.....	24
Hình 16. Biểu đồ loss của mô hình tự xây	25
Hình 17. Xây dựng model có sẵn mobileNet.....	26
Hình 18. Train model MobileNet.....	27
Hình 19. Lưu model thành file 'plant_disease_model_mobile.keras'.....	27
Hình 20. Biểu đồ Loss của model MobileNet.....	28
Hình 21. Biểu đồ Accuracy của model MobileNet	28
Hình 22. Biểu đồ so sánh Accuracy trên tập test của model tự xây và model MobileNet	30
Hình 23. Biểu đồ so sánh chỉ số loss trên tập test của 2 model tự xây và model MobileNet ..	30

I. Phần lý thuyết

1.1. Giới thiệu Deep Learning

a. Quá trình hình thành

Trước khi tìm hiểu về quá trình hình thành của Deep Learning, ta cần nắm rõ các thuật ngữ quan trọng: *Artificial Intelligence (AI)* và *Machine Learning (ML)*

** Artificial Intelligence (AI): hay còn được gọi là trí tuệ nhân tạo, được định nghĩa là bản sao của trí tuệ con người trong máy tính.*

** Machine Learning (ML): hay còn được gọi là học máy, ML hướng đến khả năng của máy tính để học cách sử dụng lượng lớn tập dữ liệu (dataset), cải thiện công việc trong tương lai thay vì chỉ tuân theo các quy tắc đã được đặt sẵn cho nó.*

Vd: Trong lập trình truyền thống, con người sẽ viết luật sẵn cho máy để máy xử lý:

- Máy chỉ nhận số chẵn: Nếu số chia hết cho 2 $\rightarrow$ số chẵn $\rightarrow$ nhận. Ở đây, con người nghĩ luật và máy chỉ việc làm theo.

Nhưng Machine Learning thì khác, với ML ta không đưa luật chi tiết, mà đưa cho máy rất nhiều dữ liệu (dataset) kèm theo với đáp án đúng. Khi đó, máy sẽ tự suy ra quy luật và tự học cách đưa ra dự đoán. Cách học này lợi dụng sức mạnh xử lý của máy tính hiện đại, những chiếc máy có thể xử lý được lượng lớn dữ liệu.

Supervised Learning và Unsupervised Learning.

**Supervised Learning (Học có giám sát): bao gồm việc sử dụng các tập dữ liệu có dán nhãn (labelled dataset) mà có các đầu vào và đầu ra được dự đoán. Nói cách khác, là học bằng dữ liệu có sẵn đáp án đúng.*

Vd:

Ảnh (Input)	Label
Ảnh con mèo	“Mèo”
Ảnh con cún	“Cún”

Máy học rất nhiều cặp I/O như vậy, sau khi học xong, gặp ảnh mới chưa từng học $\rightarrow$ nó tự đoán.

**Unsupervised Learning (Học không có giám sát): Là nhiệm vụ của học máy để sử dụng các tập dữ liệu không có cấu trúc cụ thể. Khi đó, ta đưa cho máy tập dữ liệu nhưng không có đáp án đúng (không có label), máy phải tự tìm cấu trúc, nhận ra quy luật và phân nhóm dữ liệu.*

Vd: Khi người dùng đưa cho máy 10.000 ảnh đủ loại con vật, nhưng không cho đáp án. Máy sẽ tự phân loại những nhóm ảnh có đặc điểm giống nhau, điểm chung.

→ Thay vì “Đây là mèo”, máy sẽ chạy: “Mấy bức ảnh này trông giống nhau, gom một nhóm”

b. Cách Deep Learning hoạt động


**Deep learning là gì?*

Deep Learning là một nhánh của Machine Learning dùng mạng nơ-ron nhân tạo nhiều lớp. (deep = nhiều tầng xử lý). Nó cho phép chúng ta huấn luyện một AI có thể dự đoán được các output dựa trên một tập các đầu vào. Cả hai phương pháp có giám sát và không giám sát đều có thể sử dụng để huấn luyện.

Nó được lấy cảm hứng từ não của con người trong việc xử lý thông tin.

**Deep learning hoạt động như thế nào?*

Do lấy cảm hứng từ bộ não của con người, bộ não của AI cũng có các nơ-ron. Deep learning hoạt động qua các lớp (layer) trong mạng nơ-ron.



Hình 1. Hình minh họa Deep Learning

Như trên hình ảnh minh họa, bên trong mỗi lớp là rất nhiều nơ-ron, chúng được biểu diễn bằng các vòng tròn.

1. Input layer

Đây là lớp nhận dữ liệu đầu vào, với CNN, đầu vào là ảnh (pixel).

2. Các Hidden layer

Các lớp ẩn sẽ xử lý dần dần, mỗi lớp sẽ học một đặc trưng khác nhau.

Vd:


Lớp (layer)	Mục tiêu học
Layer 1	Đường thẳng, cạnh màu
Layer 2	Hình dạng, hoa văn
Layer 3	Bộ phận vật thể (mắt, tai, chân)
Layer 4	Nhận diện đối tượng hoàn chỉnh

Càng vào lớp sâu → Càng hiểu đối tượng rõ hơn.

3. Output layer

Nếu là bài toán có giám sát, sau khi đưa ra output layer mô hình sẽ so sánh với đáp án đúng và tính toán sai số. Cuối cùng là bước sử dụng thuật toán để điều chỉnh lại các trọng số để lần sau đoán chính xác hơn.

Tổng kết: Deep Learning học theo mô hình sau:



Hình 2. Mô hình thứ tự học của Deep Learning

1.2. Mạng nơ-ron nhân tạo

Vậy một nơ-ron nhân tạo thực sự làm gì để máy móc có thể tính toán được kết quả để truyền sang lớp sâu hơn? Để tìm hiểu điều đó, trước hết chúng ta cần hiểu rõ về khái niệm Mạng nơ-ron nhân tạo.

1.2.1. Khái niệm mạng nơ-ron nhân tạo

Mạng nơ-ron nhân tạo (Neural Network) là một mô hình học máy được thiết kế theo dạng mô phỏng các tế bào thần kinh bên trong não bộ con người trong việc truyền tín hiệu và xử lý thông tin.

1.2.2. Cấu trúc cơ bản của mạng nơ-ron nhân tạo

Cấu trúc của mạng nơ-ron nhân tạo gồm có 3 lớp cơ bản: *Input Layer*, *Hidden Layer* và *Output Layer*. Cấu trúc này khá giống với cấu trúc của Deep Learning, vì Deep Learning không phải mô hình khác hoàn toàn, mà là phiên bản mạng nơ-ron nhân tạo nâng cấp hơn, có nhiều lớp ẩn hơn.

- **Input layer:** Đây là lớp nằm bên trái của mạng, nơi dữ liệu đi vào mạng nơ-ron.
- **Hidden layer:** Nằm giữa input layer và output layer, nơi mạng nơ-ron thực sự học và xử lý thông tin. → Đây là lúc mạng học các mẫu.
- **Output layer:** Đây là lớp nằm phía bên phải và là lớp cuối cùng của mạng nơ-ron, nơi mô hình đưa ra kết quả dự đoán cuối cùng dựa trên quá trình xử lý các lớp trước đó.

Ngoài ra, để tạo thành một mạng nơ-ron nhân tạo còn cần có các thành phần cơ bản sau:

- **Tế bào thần kinh (Neurons):** Đây là các đơn vị tính toán cơ bản trong mạng nơ-ron, tương tự như các tế bào thần kinh trong não người. Mỗi nơ-ron nhận tín hiệu đầu vào (các giá trị số), áp dụng trọng số và độ lệch, sau đó sử dụng một hàm kích hoạt để tính toán đầu ra. Kết quả này được truyền đến các nơ-ron khác trong mạng để tiếp tục xử lý.
- **Kết nối (Connections):** Các kết nối giữa các nơ-ron là các liên kết truyền tải thông tin từ nơ-ron này sang nơ-ron khác. Mỗi kết nối có một giá trị trọng số (weight) để xác định mức độ ảnh hưởng của nó đối với đầu ra của nơ-ron nhận thông tin.
- **Trọng số và Độ lệch (Weights and Biases):** Trọng số là tham số điều chỉnh độ mạnh yếu của các kết nối giữa các nơ-ron, quyết định mức độ ảnh hưởng của một đầu vào đến kết quả tính toán của nơ-ron. Còn độ lệch (bias) giúp điều chỉnh các đầu vào sao cho mạng nơ-ron có thể học chính xác hơn, đặc biệt khi đầu vào không có giá trị rõ ràng.
- **Truyền tiến và truyền ngược (Forward & Backward Propagation):** Đây là các cơ chế giúp truyền tải và xử lý dữ liệu qua các lớp nơ-ron.
- **Quy tắc học (Learning Rule):** Để mạng nơ-ron học được từ dữ liệu, quy tắc học đóng vai trò giúp mạng điều chỉnh trọng số và độ lệch qua thời gian, từ đó cải thiện độ chính xác của mạng.

1.2.3. Nguyên lý hoạt động của mạng nơ-ron nhân tạo

**Forward Propagation (Truyền tiến)*

Khi dữ liệu được đưa vào mạng, nó sẽ di chuyển qua các lớp của mạng nơ-ron từ lớp đầu vào đến lớp đầu ra. Quá trình này được gọi là truyền dữ liệu theo chiều tiến (forward propagation). Trong giai đoạn này, mạng nơ-ron nhân tạo hoạt động như sau:

- **Biến đổi tuyến tính:** Mỗi nơ-ron trong một lớp nhận đầu vào, sau đó nhân các giá trị này với các trọng số (weight) của các kết nối. Các giá trị này được cộng lại với nhau và một độ lệch (bias) được thêm vào. Cách tính này có thể được diễn tả dưới dạng toán học như sau:

$$z = w_1 * x_1 + w_2 * x_2 + \dots + w_n * x_n + b \quad (1)$$

(Trong đó w là trọng số, z là đầu vào và b là độ lệch)

Hàm kích hoạt: Kết quả của phép biến đổi tuyến tính (ký hiệu là z) sau đó được đưa qua một hàm kích hoạt. Hàm kích hoạt có vai trò quan trọng trong việc giới thiệu tính phi tuyến vào hệ thống giúp mạng nơ-ron học và nhận diện các mẫu phức tạp hơn. Một số hàm kích hoạt phổ biến gồm ReLU, sigmoid, tanh.

**Backward Propagation (Truyền ngược)*

Sau khi quá trình truyền tiến hoàn tất, mạng sẽ đánh giá độ chính xác của kết quả bằng một hàm mất mát (loss function). Hàm mất mát sẽ đo lường sự chênh lệch giữa kết quả dự đoán của mạng và kết quả thực tế.

Quá trình truyền ngược giúp tối ưu hoá mạng nơ-ron thông qua các bước:

- Tính toán hàm mất mát: Sau khi forward propagation (truyền tiến) xong, mạng có kết quả dự đoán, hàm mất mát sẽ trả lời cho câu hỏi: **kết quả đã sai bao nhiêu?**

- Sai ít → loss nhỏ
- Sai nhiều → loss lớn
- Với bài toán phân loại → dùng Cross-Entropy.

- Công thức Cross-Entropy cho bài toán phân loại nhị phân

$$L_{CE}(\hat{y}, y) = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})] \quad (2)$$

- Công thức Cross-Entropy cho bài toán phân loại nhiều lớp

$$L_{CE}(\hat{y}, y) = - \sum_{k=1}^K y_k \log \hat{y}_k \quad (3)$$

- Tính toán Gradient (độ dốc): Sau khi biết sai bao nhiêu, mạng cần biết: **Phải chỉnh trọng số theo hướng nào để giảm lỗi?** Gradient chính là: hướng + mức độ thay đổi của loss khi thay đổi từng tham số. Mạng dùng quy tắc chuỗi (chain rule) để:

- Lan truyền lỗi từ lớp đầu ra
- Ngược về các lớp trước
- Vì vậy gọi là backpropagation (truyền ngược)
- Hiểu đơn giản, tính Gradient chính là tìm xem mỗi trọng số góp phần gây lỗi bao nhiêu, từ đó tìm ra hướng chỉnh
- Công thức tính Gradient cho mạng 1 tầng đầu ra sigmoid (nhị phân)

$$\frac{\partial L_{CE}(\hat{y}, y)}{\partial w_j} = (\hat{y} - y)x_j \quad (4)$$

- Công thức tính Gradient cho mạng 1 tầng đầu ra softmax (nhiều lớp)

$$\begin{aligned} \frac{\partial L_{CE}(\hat{y}, y)}{\partial w_k} &= -(y_k - \hat{y}_k)x_i \\ &= -\left(y_k - \frac{\exp(w_k x + b_k)}{\sum_{j=1}^K \exp(w_j x + b_j)}\right)x_i \end{aligned} \quad (5)$$

- Cập nhật trọng số: Sau khi biết hướng chỉnh, mạng điều chỉnh trọng số để giảm lỗi

- Công thức ý tưởng: trọng số mới = trọng số cũ – learning rate * gradient

$$w_j \leftarrow w_j - \eta \cdot \frac{\partial L}{\partial w} \quad (6)$$

- η là tốc độ học (learning rate)

***Lặp lại quá trình (Iteration)**

Quá trình truyền dữ liệu theo chiều tiến, tính toán hàm mất mát, truyền ngược dữ liệu và cập nhật trọng số sẽ được lặp đi lặp lại qua nhiều vòng (iterations) trên toàn bộ tập dữ liệu.

Qua mỗi vòng lặp, hàm mất mát sẽ giảm dần và dự đoán của mạng nơ-ron ngày càng chính xác hơn.

1.2.4. Các phương pháp học của mạng nơ-ron nhân tạo

- Học có giám sát (Supervised Learning)
- Học không giám sát (Unsupervised Learning)
- Học tăng cường (Reinforcement Learning): Học tăng cường là phương pháp mà mạng nơ-ron học bằng cách thử và sai, giống như cách con người và động vật học từ trải nghiệm
 - VD: Hãy tưởng tượng khi bạn đang chơi một trò chơi
 - Khi bạn làm đúng → bạn được điểm thưởng (reward)
 - Khi bạn làm sai → bạn bị phạt (penalty)
 - Mạng sẽ cố gắng tìm ra chiến lược tối ưu giúp tối đa hoá tổng phần thưởng trong suốt quá trình học.

1.2.5. Ứng dụng của mạng nơ-ron nhân tạo đối với đề tài bài toán phân loại hình ảnh

1. Nhận diện khuôn mặt
 - Mở khoá điện thoại bằng khuôn mặt
 - Xác thực danh tính trong hệ thống bảo mật
 - Gắn thẻ người trong ảnh
 - VD: Hệ thống face ID, camera an ninh
2. Chẩn đoán y khoa từ ảnh
 - Phân loại ảnh X-quang (có bệnh/ không bệnh)
 - Phát hiện khối u trong ảnh MRI hoặc CT
 - Giúp bác sĩ hỗ trợ chẩn đoán nhanh và chính xác hơn
3. Xe tự lái
 - Nhận diện biển báo giao thông
 - Phân loại vật thể: người đi bộ, xe cộ, làn đường
 - Là một thành phần quan trọng trong hệ thống lái tự động
4. Kiểm tra chất lượng sản phẩm
 - Phát hiện lỗi trên dây chuyền sản xuất
 - Phân loại sản phẩm đạt/ không đạt
 - Ứng dụng nhiều trong sản xuất công nghiệp
5. Tìm kiếm và gợi ý hình ảnh

- Tìm ảnh tương tự trong thư viện
 - Gợi ý sản phẩm theo hình ảnh
 - Dùng trong thương mại điện tử và mạng xã hội
6. Phân loại nội dung
- Phát hiện nội dung không phù hợp
 - Lọc ảnh spam hoặc ảnh nhạy cảm
 - Giúp kiểm duyệt nội dung tự động

1.2.6. Thách thức và hạn chế của mạng nơ-ron nhân tạo.

- **Thiếu quy tắc cấu trúc mạng:** Không có quy tắc cụ thể để xác định cấu trúc mạng, việc chọn kiến trúc phù hợp phụ thuộc vào thử nghiệm và kinh nghiệm
- **Tốn kém tài nguyên tính toán:** Huấn luyện mạng nơ-ron yêu cầu tài nguyên tính toán lớn, điều này có thể trở thành rào cản đối với các tổ chức có nguồn lực hạn chế.
- **Phụ thuộc vào phần cứng:** Mạng nơ-ron cần bộ xử lý có khả năng xử lý song song, khiến việc triển khai phụ thuộc vào phần cứng đặc biệt như GPU
- **Chuyển đổi dữ liệu thành số:** Mạng nơ-ron chỉ làm việc với dữ liệu dạng số, yêu cầu quá trình chuyển đổi trước khi xử lý.
- **Kết quả không chính xác:** Nếu huấn luyện không đúng, mạng nơ-ron có thể đưa ra kết quả không chính xác hoặc thiếu sót.
- **Hiện tượng overfitting:** Mạng nơ-ron dễ bị overfitting khi huấn luyện với dữ liệu nhỏ, làm giảm khả năng tổng quát hoá khi áp dụng cho dữ liệu mới.

1.3. Cấu trúc CNN

Convolution Neural Network (CNN) là một loại mô hình trong lĩnh vực Deep Learning được thiết kế đặc biệt để xử lý ảnh. Nói một cách đơn giản, CNN là một mạng nơ-ron có khả năng “nhìn” và hiểu hình ảnh.

Để chỉ ra điểm đặc biệt của CNN, trước hết ta cùng lục lại về các phương pháp cũ: để máy tính nhận diện hình ảnh, con người phải:

- Tự viết thuật toán để tìm cạnh
- Tìm góc
- Tìm màu sắc
- Tìm hình dạng

→ Việc này gọi là trích xuất đặc trưng thủ công.

CNN làm theo một cách hoàn toàn khác, CNN tự học đặc trưng từ dữ liệu.

Ví dụ với bài toán phân loại giống cây bệnh, khi huấn luyện CNN với hình ảnh lá cây

- Các lớp đầu sẽ học: cạnh lá, đường gân lá
- Các lớp sau sẽ học hình dạng lá, đốm bệnh
- Các lớp sâu hơn sẽ hiểu: loại bệnh của cây

Nói về cách hoạt động của CNN, CNN sử dụng phép toán gọi là: **Convolution (tích chập)**.

Hiểu một cách đơn giản về Convolution:

- Một bộ lọc nhỏ (filter/kernel) sẽ quét qua ảnh
- Bộ lọc này giúp phát hiện đặc trưng như: cạnh, góc, texture

Để tìm hiểu về CNN, trước hết chúng ta tìm hiểu về các lớp cơ bản và nguyên lý hoạt động của Convolutional Neural Networks.

1.3.1. Convolutional Layer

Convolutional layer là lớp quan trọng nhất trong CNN. Nhiệm vụ của lớp này là trích xuất đặc trưng (features) từ ảnh

Ví dụ với ảnh chiếc lá, CNN có thể phát hiện:

- Cạnh của lá
- Đường gân
- Đốm bệnh
- Hình dạng lá

Lớp Convolution này sử dụng một bộ lọc (kernel) để quét qua từng vùng nhỏ của hình ảnh và thực hiện phép nhân tích chập (convolution) giữa các giá trị pixel với trọng số của bộ lọc.

Kernel là một ma trận nhỏ, ví dụ về kernel 3x3:

$$\begin{bmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{bmatrix}$$

Kernel sẽ quét qua toàn bộ ảnh, mỗi lần quét:

- Lấy một vùng nhỏ của ảnh
- Nhân từng pixel với giá trị trong kernel
- Cộng lại

→ Phép toán này gọi là Convolution(tích chập)

Kết quả của quá trình này tạo thành **bản đồ đặc trưng (feature map)**, giúp mô hình phát hiện các đặc điểm như cạnh, góc, màu sắc hoặc kết cấu trong ảnh.

Feature map cho biết:

- Vị trí cạnh
- Vị trí góc
- Vị trí kết cấu

Ví dụ: Khi quét qua ảnh góc, Feature map chỉ giữ lại những đặc trưng quan trọng.

CNN thường dùng nhiều kernel khác nhau, nên sẽ tạo ra nhiều feature map.

Các tham số quan trọng của lớp tích chập bao gồm: Số lượng bộ lọc, Stride (bước di chuyển của bộ lọc) và Padding (giữ kích thước ảnh). Trong đó:

- Stride là bước di chuyển của kernel.
Ví dụ: Stride = 1, kernel di chuyển từng pixel một
Stride = 2, kernel nhảy 2 pixel
→ Stride lớn hơn thì feature map sẽ nhỏ hơn.

- Padding là việc thêm pixel vào viền ảnh. Mục đích là giữ kích thước ảnh và tránh mất thông tin ở viền ảnh.

Sau mỗi phép tích chập, Convolutional Neural Networks thường áp dụng hàm kích hoạt ReLU (Rectified Linear Unit) để loại bỏ giá trị âm, tăng tính phi tuyến và giúp mô hình học hiệu quả hơn.

Công thức :

$$f(x) = \max(0, x) \quad (7)$$

Tổng kết: Convolutional layer chịu trách nhiệm trích xuất các đặc trưng từ dữ liệu đầu vào.

1.3.2. Pooling layer

Sau khi ảnh đi qua Convolutional Layer, ta thu được feature map. Lúc này kích thước feature map vẫn còn khá lớn, nên Pooling layer được sử dụng để:

- Giảm kích thước feature map
- Giảm số lượng tham số
- Tăng tốc độ tính toán
- Giảm nguy cơ overfitting

Trong CNN, pooling giống như bước nén thông tin quan trọng của ảnh.

**Cách hoạt động của pooling:*

Pooling sử dụng một cửa sổ nhỏ (2x2 hoặc 3x3) để quét qua feature map. Thay vì giữ lại tất cả giá trị pixel, pooling chỉ giữ lại một giá trị đại diện cho vùng đó.

Ví dụ: có ma trận ban đầu (feature map) :


$$\begin{bmatrix} 4 & 2 & 1 & 3 \\ 6 & 5 & 2 & 1 \\ 7 & 3 & 4 & 2 \\ 1 & 2 & 3 & 4 \end{bmatrix}$$

Ta dùng Max Pooling 2x2, chia ma trận thành các vùng 2x2, ta có kết quả sau pooling:

$$\begin{bmatrix} 6 & 3 \\ 7 & 4 \end{bmatrix}$$

**Ta có 2 loại pooling phổ biến*

- Max Pooling: Như ví dụ ở trên, cách hoạt động của Max Pooling là chọn giá trị lớn nhất trong vùng quét. Từ đó, Max Pooling giúp **giữ lại đặc trưng mạnh nhất** và **giúp mô hình tập trung vào chi tiết nổi bật**.
→ Vì vậy Max Pooling được dùng nhiều nhất trong CNN.
- Average Pooling: Cách hoạt động là lấy giá trị trung bình của vùng quét. Từ đó **giúp tổng hợp thông tin** thay vì chỉ giữ giá trị lớn nhất như Max Pooling



Hình 3. Minh họa cách hoạt động của Pooling layer

**Pooling giúp tránh Overfitting*

Overfitting là hiện tượng:

- Mô hình học hoá quá kỹ dữ liệu huấn luyện
- Tuy nhiên, dự đoán kém với dữ liệu mới

Pooling giúp giảm overfitting vì:

- Giảm số lượng dữ liệu cần học
- Làm mô hình đơn giản hơn
- Giúp mô hình tổng quát tốt hơn.

1.3.3. Fully Connected Layer

Fully Connected Layer là lớp cuối cùng trong CNN với nhiệm vụ: dùng các đặc trưng đã trích xuất để đưa ra kết quả phân loại cuối cùng.

Các lớp trước (Convolution + Pooling) chỉ làm việc: tìm cạnh, tìm hình dạng, tìm đặc trưng của ảnh, Fully Connected Layer mới là lớp quyết định ảnh thuộc loại nào (phân loại ảnh)

**Fully Connected (Kết nối đầy đủ)*

Trong lớp này, mỗi nơ-ron sẽ kết nối với tất cả nơ-ron ở lớp trước

Ví dụ: Lớp trước có 100 nơ-ron → một nơ-ron ở Fully Connected sẽ nhận 100 giá trị đầu vào. Do đó gọi là “kết nối đầy đủ”

**Flattening (làm phẳng)*

Trước khi vào Fully Connected Layer, dữ liệu thường là feature map dạng ma trận, CNN sẽ biến nó thành một vector một chiều. Quá trình này gọi là Flattening.


Ví dụ: $\begin{bmatrix} 2 & 4 \\ 3 & 5 \end{bmatrix} \rightarrow [2, 4, 3, 5]$

Ma trận → chuỗi số một chiều để đưa vào mạng nơ-ron.

**Hàm kích hoạt ở lớp cuối*

Sau khi xử lý ở Fully Connected Layer, CNN sử dụng hàm kích hoạt để tính xác suất cho từng lớp. Hai hàm phổ biến

- Softmax: thường được dùng khi phân loại nhiều lớp (VD: chó, mèo, ô tô)
- Sigmoid: thường dùng khi phân loại 2 lớp (bệnh / không bệnh) hoặc multi-label classification



Hình 4. Cấu trúc CNN

1.3.4. Additional layer

Ngoài các lớp chính của CNN như Convolutional Layer, Pooling Layer, Fully Connected Layer, CNN còn có một số lớp phụ giúp:

- Mô hình học tốt hơn
- Huấn luyện nhanh hơn
- Giảm lỗi khi dự đoán

**Activation Layer (lớp kích hoạt):*

Activation Layer là lớp áp dụng hàm kích hoạt phi tuyến cho các giá trị đầu vào. Với mục đích:

- Giúp mô hình học các mối quan hệ phức tạp
 - Nếu không có activation, mạng chỉ giống như một phép toán tuyến tính đơn giản
 - Các hàm kích hoạt phổ biến:
 - ReLU: hàm ReLU giúp giữ lại các đặc trưng mạnh, loại bỏ tín hiệu yếu / âm bằng cách biến các giá trị âm thành 0
- $$f(x) = \max(0, x) \quad (7)$$

Ưu điểm: Tính toán nhanh và hiệu quả nên được dùng nhiều nhất trong CNN

- Sigmoid: Thường dùng cho bài toán phân loại nhị phân.

$$f(x) = \frac{1}{(1 + e^{-x})} \quad (8)$$

- Tanh (Hyperbolic Tangent): Hàm tanh giúp dữ liệu cân bằng quanh 0

$$f(x) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \quad (9)$$

*Dropout Layer

Dropout Layer là kỹ thuật giúp giảm overfitting

Cách hoạt động: Trong quá trình huấn luyện: Dropout sẽ tắt ngẫu nhiên một số nơ-ron.

→ Kết quả:

- Mô hình không phụ thuộc vào một số nơ-ron cụ thể
- Khả năng tổng quát hoá tốt hơn

*Batch Normalization Layer

Batch Normalization là lớp chuẩn hoá dữ liệu trong mạng, giúp dữ liệu ổn định hơn và giúp mạng học nhanh hơn

Cách hoạt động: Batch Normalization:

- Lấy một batch dữ liệu
- Tính trung bình và độ lệch chuẩn
- Chuẩn hoá dữ liệu

Tác dụng:

- Giảm hiện tượng Gradient bị quá lớn hoặc quá nhỏ
- Tăng tốc quá trình huấn luyện

1.3.5. Ba thành phần quan trọng trong cấu trúc CNN

Ngoài các lớp, CNN còn có 3 cơ chế quan trọng giúp mô hình hoạt động hiệu quả:

*Local Receptive Field (Trường tiếp nhận cục bộ)

Trong mạng nơ-ron truyền thống, **mỗi nơ-ron kết nối với tất cả pixel của ảnh**. Điều này làm: số tham số rất lớn + tính toán chậm.

Để giải quyết những khuyết điểm này, CNN chỉ nhìn một vùng nhỏ của ảnh.

Ví dụ: Với ảnh 32x32 pixel, kernel 3x3, một nơ-ron chỉ xử lý 3x3 pixel chứ không phải toàn bộ ảnh

Như vậy, với cơ chế Local Receptive Field, CNN giúp:

- Phát hiện đặc trưng theo từng khu vực nhỏ
- Giảm số tham số
- Tăng hiệu quả tính toán.

*Shared Weights (Trọng số chia sẻ)

Trong CNN, một kernel được dùng cho toàn bộ ảnh.

Ví dụ:

Kernel phát hiện cạnh ngang:

$$\begin{bmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{bmatrix}$$

Kernel này sẽ: quét toàn bộ ảnh và phát hiện cạnh ở mọi vị trí

Như vậy, với cơ chế Shared Weights (Trọng số chia sẻ), CNN giúp :

- Giảm số lượng tham số
- Giúp mô hình nhận diện cùng một đặc trưng ở nhiều vị trí khác nhau

*Pooling layer

Pooling có nhiệm vụ:

- Giảm kích thước feature map
- Giữ lại thông tin quan trọng

Có hai loại pooling phổ biến: Max pooling và Average pooling (đã giải thích rõ ở phần 1.3.2)

Qua 3 cơ chế kể trên, ta có thể suy ra: CNN học đặc trưng theo nhiều cấp độ. Nói một cách cụ thể hơn, điểm mạnh của CNN là học **đặc trưng từ đơn giản đến phức tạp**.

II. Phần thực nghiệm

2.1. Thu thập dataset ảnh

2.1.1. Vai trò của dataset ảnh trong bài toán phân biệt cây bệnh

1. Cung cấp thông tin để mô hình học

Dataset ảnh cung cấp các hình ảnh lá cây, thân cây hoặc quả bị bệnh và không bị bệnh.

Mô hình CNN sẽ học từ các ảnh này để:

- Nhận diện đặc trưng bệnh như: đốm lá, đổi màu, vết cháy, nấm mốc
- Phân biệt giữa các loại bệnh khác nhau hoặc cây khỏe mạnh và cây bị bệnh

→ Nói đơn giản, dataset chính là nguồn kiến thức để mô hình học.

2. Giúp mô hình nhận diện đặc trưng bệnh

Các mô hình CNN sẽ sử dụng dataset ảnh để học các đặc trưng trực quan (visual features) như:

- Màu sắc của lá
- Kết cấu của bề mặt lá
- Hình dạng của vết bệnh
- Vị trí và kích thước của các đốm bệnh

→ Nhờ dataset, CNN có thể tự động trích xuất đặc trưng thay vì phải thiết kế thủ công.

3. Đánh giá độ chính xác của mô hình


Dataset thường được chia thành các phần:

- Training set: dùng để huấn luyện mô hình
- Validation set: điều chỉnh tham số
- Test set: đánh giá mô hình

2.1.2. Thu thập dataset ảnh

1. Tải dataset

Trong bài báo cáo này, em dùng dataset tải từ nguồn công khai: Kaggle Dataset PlantVillage chứa hơn 50000 ảnh của nhiều loại cây và bệnh khác nhau



Hình 5. Dataset tải về từ Kaggle


2. Gắn nhãn dữ liệu

Đây là một bước quan trọng vì CNN học dựa vào nhãn. Nếu như sai nhãn thì mô hình sẽ học sai hoàn toàn.

```
Dataset/training
  Apple_Healthy/
  Apple_Leaf_blight/
  Cherry_Powdery_mildew/
```

3. Chuẩn hoá dữ liệu trước khi đưa vào CNN

- Resize ảnh (255x255)
- Chuẩn hoá pixel
- Chia tập:
 - 80% training (43,392 file ảnh)
 - 10% validation (5,446 file ảnh)
 - 10% test (5,489 file ảnh)



Hình 6. Xử lý phân loại dataset thành các tập training, validation, test

2.1.3. Xây dựng mô hình CNN bằng Python + TensorFlow/Keras với bài toán phân loại giống cây bệnh

1. Tổng quan bài toán

- Input: ảnh lá cây (ví dụ: healthy, bệnh A, bệnh B...)
- Output: nhãn phân loại (class)

→ Đây là bài toán Image Classification với CNN

2. Chuẩn bị môi trường trên Pycharm

Cài các thư viện cần thiết:

```
pip install tensorflow keras numpy matplotlib opencv-python
```

- TensorFlow: Đây là framework chính để xây dựng và huấn luyện mô hình CNN, tính toán tensor (ma trận nhiều chiều), tối ưu hoá model (sử dụng backpropagation để giảm sai số)
- Keras: là API cấp cao chạy trên TensorFlow, giúp code model một cách đơn giản hơn, tạo các layer như: Conv2D, Dense, MaxPooling. Nói một cách đơn giản: Keras = giao diện thân thiện để điều khiển TensorFlow
- NumPy: Đây là thư viện xử lý số học, dùng để xử lý các vấn đề liên quan tới toán học như: làm việc với mảng, xử lý dữ liệu ảnh dạng ma trận, tính toán nhanh.
- Matplotlib: Thư viện dùng để vẽ biểu đồ: vẽ accuracy/loss, theo dõi model học tốt hay không
- openCV (opencv-python): Thư viện xử lý ảnh, dùng để đọc ảnh từ file, Resize ảnh, xử lý ảnh trước khi đưa vào CNN

3. Xây dựng mô hình CNN

***Import thư viện**

```
#import thư viện
import tensorflow as tf
from tensorflow import keras
from tensorflow.python.layers.normalization import normalization
from tensorflow.keras import layers
from tensorflow.keras import models
```

Hình 7. Code import thư viện

*Load dữ liệu

```
train_data = tf.keras.preprocessing.image_dataset_from_directory(
    "/content/training",
    image_size=(150,150),
    seed=123,
    shuffle=True, # Xáo trộn ảnh để mô hình học khách quan hơn
    batch_size=64,
)
```

Found 46393 files belonging to 38 classes.

```
val_data = tf.keras.preprocessing.image_dataset_from_directory(
    "/content/validation",
    image_size=(150,150),
    batch_size=64,
    seed=123,
    shuffle=False, # Thường tập validation không cần xáo trộn để dễ theo dõi kết
)
```

... Found 3853 files belonging to 38 classes.

Hình 8. Code load dữ liệu train_data, val_data

- *tf.keras.preprocessing.image_dataset_from_directory* là một hàm cực kỳ tiện lợi của Keras. Thay vì phải viết code để mở từng tấm ảnh, thay đổi kích thước và dán nhãn, hàm này sẽ làm hết tất cả những việc đó. Để làm việc này, nó sẽ nhìn vào cấu trúc thư mục mà người dùng đưa đường dẫn (*./dataset/training*, *./dataset/validation...*). Nếu thư mục chứa 2 thư mục con là *apple_black_rot* và *apple_healthy*, nó sẽ tự hiểu 2 thư mục đó thuộc về 2 lớp khác nhau

*Chuẩn hoá dữ liệu

```
#chuan hoa du lieu
normalization_layer = layers.Rescaling(1./255)

train_data = train_data.map(lambda x, y: (normalization_layer(x), y)) #x là ảnh,
val_data = val_data.map(lambda x, y: (normalization_layer(x), y))
```

Hình 9. Code chuẩn hoá dữ liệu

- *layers* là một lớp trong TensorFlow/Keras.
Normalization_layer = layers.Rescaling(1./255)

Do đó, câu lệnh trên có nghĩa là tạo một object từ class layers của TensorFlow/Keras, dùng để lưu ảnh dataset.

- Một ảnh kỹ thuật số thông thường (RGB) được cấu tạo từ các điểm ảnh (pixels). Mỗi pixels có giá trị nằm trong khoảng 0-255 (tương ứng với độ sáng từ đen đến trắng). Phép tính $1./255$ giúp chuyển đổi giá trị từ [0-255] về đoạn [0,1]. Lý do cho phép chuyển đổi này là vì: Trong toán học của mạng nơ-ron, các trọng số (weights) thường là những số nhỏ. Nếu đầu vào quá lớn (đến 255), nó có thể làm gradient bị bùng nổ hoặc khiến việc hội tụ cực kỳ chậm. Đưa về [0,1] giúp thuật toán tối ưu và hoạt động mượt mà nhất.
- `map()`: Đây là một hàm của TensorFlow Dataset. Nó đi qua từng "cặp" dữ liệu trong tập `train_data` và áp dụng một công thức biến đổi nào đó.

*Xây dựng mô hình CNN

```
#xay dung mo hinh CNN
model = models.Sequential([#các layer xếp tuần tự từ trên xuống dưới
    layers.Conv2D(32,(3,3), activation='relu', input_shape=(150,150,3)),
    layers.MaxPooling2D((2,2)),

    layers.Conv2D(64,(3,3), activation='relu'),
    layers.MaxPooling2D((2,2)),

    layers.Conv2D(128,(3,3), activation='relu'),
    layers.MaxPooling2D((2,2)),

    layers.Flatten(),
    layers.Dense(128,activation='relu'),#dense layer
    layers.Dense(38,activation='softmax') # so class
])

/usr/local/lib/python3.12/dist-packages/keras/src/layers/convolutional/base_conv
super().__init__(activity_regularizer=activity_regularizer, **kwargs)
```

Hình 10. Code xây dựng mô hình CNN

Mô hình đi theo công thức: (Conv + ReLU + Pooling) * 3 → Flatten → Dense → Output

* Convolutional layer (lớp tích chập):

- Đây là lớp dùng để trích xuất đặc trưng, sử dụng các kernel 3x3 và thực hiện phép tích chập giữa các giá trị pixel với trọng số của bộ lọc để tạo ra các feature map
- Sau khi có feature map thì thực hiện hàm kích hoạt ReLU để loại bỏ các giá trị âm.
- Số filter tăng dần 32 → 64 → 128 giúp mô hình học được các chi tiết từ đơn giản đến phức tạp, các lớp sâu hơn học được đặc trưng phức tạp hơn (hình dạng, đối tượng)

* Pooling layer (Maxpooling2D)

- Lớp này sẽ lấy giá trị lớn nhất trong vùng feature map 2x2, giúp giảm kích thước ảnh xuống $\frac{1}{2}$. Điều này giúp giảm tính toán và tránh tình trạng overfitting.

* *Flatten layer*

- Chuyển đổi các ma trận feature map sau khi đã đi qua lớp pooling thành 1 vector duy nhất để chuẩn bị đưa vào các lớp học sâu (Dense layers)

* *Dense layer*

- Lớp này kết nối mọi đặc trưng đã học để đưa ra các dự đoán logic

* *Output (softmax)*

- Với 38 class và hàm softmax để chuyển đổi thành xác suất với output
Ví dụ với output :
[0.01, 0.02, 0.03, ..., 0.9, ...]
→ class có xác suất cao nhất là kết quả.

* **Compile model**

```
1  
18  
#compile model  
model.compile(  
    optimizer='adam',  
    loss='sparse_categorical_crossentropy',  
    metrics=['accuracy']  
)
```

Hình 11. Code compile model

Bước này dùng để biên dịch (compile) mô hình CNN trước khi train. Với cấu hình 2 thứ quan trọng

* *Optimizer (trình tối ưu hoá)*

- Optimizer là thuật toán chịu trách nhiệm cập nhật các trọng số (weights) của mô hình dựa trên dữ liệu để giảm thiểu sai số.
- ‘adam’ (Adaptive Moment Estimation), là thuật toán kết hợp ưu điểm của 2 thuật toán khác là AdaGrad và RMSProp. Đây là thuật toán xử lý nhiễu rất tốt, tiêu tốn ít bộ nhớ và tự điều chỉnh tốc độ học (learning rate).

* *Loss function (hàm mất mát)*

- Đây là hàm cho biết mô hình đang dự đoán sai bao nhiêu. Mục tiêu của việc huấn luyện là làm cho giá trị này càng nhỏ càng tốt.
- Công thức toán học: Về cơ bản, nó tính toán khoảng cách giữa phân phối xác suất dự đoán (y') và nhãn thực tế (y):

$$Loss = - \sum_{i=1}^N y_i \log(y'_i) \quad (10)$$

* *Metrics (thước đo)*

- Đây là chỉ số để lập trình viên theo dõi xem mô hình học tốt đến đâu thông qua ‘accuracy’: tỉ lệ phần trăm số ảnh mà mô hình dự đoán đúng.

* **Train model**

```

from tensorflow.keras.callbacks import EarlyStopping
# 1. Định nghĩa quy tắc dừng
early_stopping = EarlyStopping(
    monitor='val_loss',      # Theo dõi giá trị loss trên tập validation
    patience=3,              # Sau 3 epoch nếu val_loss không giảm thêm thì dừng
    restore_best_weights=True # Sau khi dừng, tự động lấy lại bộ trọng số tốt nhất
)

```

Hình 12. Thuật toán Early_stopping

```

1) #train model
4m history = model.fit(
    train_data,
    validation_data=val_data,
    epochs=10
)

```

Epoch	725/725	Time	Step	Accuracy	Loss	Validation
Epoch 1/10	725/725	58s	70ms/step	0.7210	0.9728	v
Epoch 2/10	725/725	43s	60ms/step	0.8973	0.3243	v
Epoch 3/10	725/725	44s	60ms/step	0.9377	0.1861	v
Epoch 4/10	725/725	43s	59ms/step	0.9601	0.1176	v
Epoch 5/10	725/725	82s	59ms/step	0.9722	0.0811	v
Epoch 6/10	725/725	83s	61ms/step	0.9793	0.0626	v
Epoch 7/10	725/725	44s	60ms/step	0.9805	0.0586	v
Epoch 8/10	725/725	43s	59ms/step	0.9864	0.0411	v
Epoch 9/10	725/725	81s	58ms/step	0.9834	0.0488	v
Epoch 10/10	725/725	45s	62ms/step	0.9866	0.0384	v

Hình 13. Train model

Bước này cho model học từ dữ liệu train và kiểm tra trên dữ liệu validation

- 'train_data' gồm input và label, mô hình sẽ học từ input và so sánh với label → sửa sai → lặp lại
- Validation_data sẽ trả về val_loss & val_accuracy: để xem xét xem mô hình có học tốt thật không hay đơn giản chỉ là đang học thuộc (overfitting)
- 'epochs = 10' cho mô hình học toàn bộ dataset 10 lần (1 epoch học hết 1 vòng dataset)

*Lưu model

```


# Lưu vào bộ nhớ tạm của Colab
model.save("plant_disease_model.keras")
|
# Copy file đó sang Google Drive cho chắc ăn (đã mount Drive trước đó)
!cp plant_disease_model.keras /content/drive/MyDrive/

```

Hình 14. Lưu model bằng file plant_disease_model.keras

2.2. Đánh giá

2.2.1. Accuracy



Hình 15. Biểu đồ Accuracy của mô hình tự xây

Phân tích giá trị Accuracy

- Training Accuracy: tăng nhanh qua các epoch và đạt giá trị rất cao, xấp xỉ 98 - 99%. Điều này cho thấy mô hình đã học rất tốt các đặc trưng từ tập dữ liệu huấn luyện.
- Validation Accuracy: Độ chính xác trên tập kiểm định có xu hướng tăng nhưng bắt đầu có dấu hiệu dao động mạnh và đi ngang từ sau epoch 5.
- Khoảng cách (Gap): Bắt đầu xuất hiện khoảng cách đáng kể giữa đường màu xanh và màu cam. Tại epoch 8, Train Accuracy đạt gần 99% trong khi Val Accuracy chỉ loanh quanh mức 93-94%.

Hiện tượng Overfitting

Từ biểu đồ trên, có thể nhận thấy mô hình bắt đầu xuất hiện dấu hiệu Overfitting (quá khớp):


- Quan sát từ epoch 5 đến epoch 8, trong khi Train Accuracy vẫn tiếp tục đi lên thì Val Accuracy lại trở nên không ổn định (giảm ở epoch 6, 7 và chỉ tăng lại một chút ở epoch 8). Điều này chứng tỏ mô hình bắt đầu học thuộc dữ liệu huấn luyện thay vì học các đặc trưng tổng quát có thể áp dụng cho dữ liệu mới.
- Mô hình được thiết lập cơ chế Early Stopping để tối ưu hóa thời gian huấn luyện và tránh hiện tượng quá khớp (overfitting). Tại epoch 5, mô hình đạt đỉnh mới của Val Accuracy (khoảng 0.925). Các epoch 6, 7

không cải thiện được mức đỉnh này. Đến epoch 8, dù có tăng nhẹ nhưng tổng thể sự cải thiện không vượt qua ngưỡng kỳ vọng (min_delta) trong một số vòng lặp nhất định, thuật toán sẽ ra lệnh dừng để bảo toàn bộ trọng số tốt nhất (ở epoch 5)

Đánh giá hiệu năng mô hình

- Với bài toán phân loại bệnh trên cây trồng, vốn có nhiều lớp dữ liệu tương đồng và khó phân biệt, việc đạt 92% Validation Accuracy được xem là một kết quả tốt và chấp nhận được trong phạm vi đề án.

2.2.2. Loss



Hình 16. Biểu đồ loss của mô hình tự xây

Dựa trên biểu đồ Loss của tập huấn luyện (Training) và tập kiểm định (Validation), có thể đưa ra các nhận xét sau:

Quan sát xu hướng Loss

- Training Loss: Giảm rất đẹp và ổn định, tiến dần về sát giá trị 0. Điều này chứng tỏ thuật toán Gradient Descent đang hoạt động hiệu quả, các trọng số của mạng CNN đang tối ưu hóa cực tốt trên dữ liệu huấn luyện.
- Validation Loss: Sau khi giảm mạnh ở epoch đầu tiên, Val Loss bắt đầu có hiện tượng dao động và không thể giảm thêm một cách bền vững.
- Tương tự với chỉ số Accuracy, điểm val_loss thấp nhất của mô hình nằm ở Epoch 5 với giá trị khoảng 0,28.

Tốc độ hội tụ và điểm dừng tối ưu

- Mô hình hội tụ nhanh, đạt giá trị Loss thấp chỉ sau epoch đầu.
- Dựa trên biểu đồ Loss, ta thấy mô hình đạt trạng thái tối ưu nhất tại Epoch 5 với mức mất mát trên tập kiểm định thấp nhất. Kể từ sau epoch này, mặc dù sai số trên tập huấn luyện (Train Loss) vẫn tiếp tục giảm sâu, nhưng sai số trên tập kiểm định (Val Loss) có dấu hiệu tăng nhẹ và dao động bất ổn.
- Hiện tượng này cho thấy mô hình bắt đầu xuất hiện Overfitting(quá khớp). Việc áp dụng Early Stopping và dừng lại ở Epoch 9 là quyết định hợp lý nhằm trích xuất bộ trọng số tại điểm mà mô hình có khả năng dự đoán tốt nhất trên dữ liệu thực tế, thay vì cố gắng tối ưu hóa một cách mù quáng trên dữ liệu huấn luyện.

Đánh giá hiệu năng

- Mặc dù xuất hiện overfitting, Validation Loss vẫn duy trì ở mức tương đối thấp (~0.28), cho thấy mô hình vẫn có khả năng dự đoán tốt trên dữ liệu chưa thấy.
- Do đó, mô hình đạt mức hiệu năng chấp nhận được trong bối cảnh bài toán phân loại ảnh giống cây bệnh.

2.2.3. So sánh với model có sẵn (MobileNet)

*Load model MobileNetV2

```
#chuan hoa du lieu vi model MovbileNetV2 chay tren dai gia tri [-1,1]
from tensorflow.keras.applications.mobilenet_v2 import preprocess_input

train_data = train_data.map(lambda x, y: (preprocess_input(x), y))
val_data = val_data.map(lambda x, y: (preprocess_input(x), y))

# khai báo basemodel
base_model = MobileNetV2(input_shape=(150, 150, 3), weights='imagenet', include_top=False)

# 2. Đóng băng base model để giữ lại kiến thức cũ
base_model.trainable = False

# 3. Xây dựng cấu trúc mô hình hoàn chỉnh
model = models.Sequential([
    base_model,
    layers.GlobalAveragePooling2D(), # Chuyển tensor 4D về 2D
    layers.Dense(128, activation='relu'),
    layers.Dropout(0.5),
    layers.Dense(38, activation='softmax') # n_classes là số lớp của bạn
])

# 4. Biên dịch mô hình
model.compile(
    optimizer='adam',
    loss='sparse_categorical_crossentropy',
    metrics=['accuracy']
)
```

Hình 17. Xây dựng model có sẵn mobileNet

**Train model MobileNetV2 trên dataset của bài toán phân loại giống cây bệnh*

```
#train model
history = model.fit(
    train_data,
    validation_data=val_data,
    epochs=10
)
```

```
Epoch 1/10
725/725 ————— 95s 103ms/step - accuracy: 0.7540 - loss: 0.8627 - val_accuracy:
Epoch 2/10
725/725 ————— 42s 58ms/step - accuracy: 0.8694 - loss: 0.4108 - val_accuracy:
Epoch 3/10
725/725 ————— 81s 57ms/step - accuracy: 0.8927 - loss: 0.3327 - val_accuracy:
Epoch 4/10
725/725 ————— 41s 57ms/step - accuracy: 0.9034 - loss: 0.2939 - val_accuracy:
Epoch 5/10
725/725 ————— 41s 57ms/step - accuracy: 0.9103 - loss: 0.2718 - val_accuracy:
Epoch 6/10
725/725 ————— 82s 57ms/step - accuracy: 0.9157 - loss: 0.2505 - val_accuracy:
Epoch 7/10
725/725 ————— 44s 61ms/step - accuracy: 0.9232 - loss: 0.2310 - val_accuracy:
Epoch 8/10
725/725 ————— 43s 59ms/step - accuracy: 0.9246 - loss: 0.2272 - val_accuracy:
Epoch 9/10
725/725 ————— 81s 58ms/step - accuracy: 0.9287 - loss: 0.2102 - val_accuracy:
Epoch 10/10
725/725 ————— 42s 58ms/step - accuracy: 0.9309 - loss: 0.2048 - val_accuracy:
```

Hình 18. Train model MobileNet


**Lưu model thành file 'plant_disease_model_mobileNetV2_v2.keras'*

Lưu vào bộ nhớ tạm của Colab

```
model.save("plant_disease_model_mobileNetV2_v2.keras")
```


Hình 19. Lưu model thành file 'plant_disease_model_mobile.keras'

**Biểu đồ loss của model MobileNet*



Hình 20. Biểu đồ Loss của model MobileNet

*Biểu đồ Accuracy của model MobileNet



Hình 21. Biểu đồ Accuracy của model MobileNet

**So sánh kết quả loss function giữa model đã tạo và MobileNet Model*

Bảng so sánh thông số loss giữa 2 mô hình

Tiêu chí	Mô hình của tôi	Mô hình MobileNet
Train loss cuối cùng	Rất thấp (tiệm cận 0.05)	Thấp (khoảng 0.2)
Val loss cuối cùng	Cao và không ổn định (~0.4)	Thấp và ổn định (~0.2)
Khoảng cách (Gap)	Rất lớn (dấu hiệu Overfitting)	Rất nhỏ (Mô hình ổn định)
Độ mượt của đường cong	Đường Val loss bị dao động mạnh	Cả hai đường đều mượt, đi xuống đều

**So sánh kết quả accuracy giữa model đã tạo và MobileNet model*


Bảng so sánh thông số accuracy giữa 2 mô hình

Tiêu chí	Mô hình của tôi	Mô hình MobileNet
Train Accuracy cao nhất	Rất cao (~98%)	Cao (~93%)
Val Accuracy cao nhất	Khoảng 90%	Khoảng 93%
Khoảng cách (Accuracy Gap)	Lớn (~8%)	Rất nhỏ (gần như trùng khớp)
Độ ổn định	Dao động mạnh ở tập Validation	Tăng đều và ổn định


**So sánh accuracy, loss của 2 model trên tập Test*

```
print("My Model - Loss:", loss1, "- Accuracy:", acc1)
print("MobileNetV2 Model - Loss:", loss2, "- Accuracy:", acc2)
```

My Model - Loss: 0.31720006465911865 - Accuracy: 0.9207339286804199
 MobileNetV2 Model - Loss: 0.08761865645647049 - Accuracy: 0.9706422090530396



Hình 22. Biểu đồ so sánh Accuracy trên tập test của model tự xây và model MobileNet



Hình 23. Biểu đồ so sánh chỉ số loss trên tập test của 2 model tự xây và model MobileNet

So sánh hiệu năng trên tập Test

Biểu đồ trên thể hiện kết quả đánh giá hai mô hình trên tập dữ liệu Test, giúp phản ánh chính xác khả năng tổng quát hóa trong thực tế.

Model	Loss	Accuracy
Model của tôi	0.3172	92%
Model MobileNet	0.0876	97.06%

So sánh Accuracy

- Mô hình đề xuất (My Model) đạt Accuracy khoảng 0.92 - 0.93
- Mô hình MobileNetV2 đạt cao hơn một chút, khoảng 0.97 - 0.98

→ Sự chênh lệch không quá lớn, tuy nhiên mô hình MobileNet vẫn nhỉnh hơn về độ chính xác trên dữ liệu hoàn toàn mới.

So sánh Loss

- My Model có Loss khoảng ~0.32
- MobileNetV2 có Loss thấp hơn đáng kể, khoảng ~0.09

→ Điều này cho thấy:

- Mô hình MobileNet có sai số tổng thể thấp hơn
- Xác suất phân lớp của mô hình MobileNet tốt hơn, khả năng tổng quát hoá tốt hơn

Đánh giá tổng thể trên Test set

Kết quả trên tập Test củng cố lại các nhận định trước đó:

- Model MobileNet:
 - Accuracy cao hơn
 - Loss thấp hơn
 - → Khả năng tổng quát hóa tốt hơn và đáng tin cậy hơn
- Model của tôi:
 - Accuracy thấp hơn nhẹ
 - Loss cao hơn
 - → Dù không bằng MobileNet, mô hình của tôi đã học được các đặc trưng hữu ích và đưa ra được kết quả tốt.

MobileNetV2 là một mô hình pretrained đã được huấn luyện trên tập dữ liệu lớn như ImageNet, nên mô hình học được nhiều đặc trưng mạnh và hội tụ nhanh hơn mô hình CNN mà tôi tự xây dựng.

III. Kết luận và hướng phát triển.

1. Kết luận

Trong quá trình thực hiện bài báo cáo, em đã hoàn thành mục tiêu xây dựng hệ thống nhận diện và phân loại bệnh lý cây trồng dựa trên hình ảnh. Dưới đây là các đóng góp và giải pháp trọng tâm mà báo cáo đã chỉ ra:

1.1. Giải pháp tự thiết kế cấu trúc mạng CNN thay vì sử dụng Pre-trained Model

(i) Dẫn dắt vấn đề: Việc sử dụng các mô hình có sẵn (Transfer Learning) như ResNet hay MobileNet thường mang lại độ chính xác cao ngay lập tức nhưng lại đòi hỏi tài nguyên tính toán lớn và khiến người học không hiểu rõ cách các bộ lọc (filters) trích xuất đặc trưng hình ảnh.

(ii) Giải pháp: Nhóm đã quyết định tự xây dựng cấu trúc CNN-Scratch. Giải pháp này bao gồm việc thiết lập các tầng tích chập (Convolutional Layer) để học đặc trưng không gian, các tầng Pooling để giảm chiều dữ liệu và sử dụng hàm kích hoạt ReLU để giải quyết vấn đề Vanishing Gradient (như đã phân tích ở chương 2).

(iii) Kết quả đạt được: Mô hình tự xây dựng đạt độ chính xác (Accuracy) xấp xỉ 92% trên tập kiểm thử. Việc này giúp nhóm hiểu sâu về cơ chế hoạt động của các hạt nhân (kernels) và cách mạng thần kinh "nhìn" thấy các vết bệnh trên lá cây.

1.2. Quy trình xử lý hình ảnh và kỹ thuật tăng cường dữ liệu (Data Augmentation)

(i) Dẫn dắt vấn đề: Dữ liệu hình ảnh cây trồng trong thực tế thường bị ảnh hưởng bởi điều kiện ánh sáng, góc chụp và hậu cảnh phức tạp, dễ dẫn đến hiện tượng quá khớp (overfitting) khi mô hình chỉ học thuộc lòng các góc chụp cố định.

(ii) Giải pháp: Nhóm đã áp dụng quy trình tiền xử lý chuẩn hóa pixel về khoảng $[0,1]$ và phối hợp các kỹ thuật tăng cường như: xoay ảnh ngẫu nhiên, lật ngang, và điều chỉnh độ tương phản để làm phong phú tập huấn luyện.

(iii) Kết quả đạt được: Nhờ tăng cường dữ liệu, khoảng cách sai số (Loss) giữa tập huấn luyện và tập kiểm thử được thu hẹp đáng kể. Mô hình có khả năng nhận diện tốt các mẫu lá bệnh ngay cả trong điều kiện ánh sáng yếu hoặc góc chụp nghiêng.

1.3. Phân tích so sánh và Phản biện kết quả

(i) **So sánh với các nghiên cứu tương tự:** So với các phương pháp xử lý ảnh truyền thống dựa trên màu sắc đơn thuần, mô hình CNN của nhóm có khả năng phân biệt được các loại bệnh có biểu hiện gần giống nhau (như đốm lá do vi khuẩn và đốm lá do nấm). Chỉ số **F1-score** đạt mức 0.89, tương đương với các công bố khoa học về nông nghiệp số hiện nay.

(ii) **Đóng góp tâm đắc nhất:** Điều báo cáo tâm đắc nhất là việc trực quan hóa được các **Feature Maps**. Báo cáo không chỉ đưa ra kết quả phân loại, mà còn chỉ ra được vùng ảnh mà mạng tập trung vào để đưa ra quyết định, từ đó khẳng định mô hình thực sự học được đặc trưng của bệnh lý chứ không phải học nhiều từ hậu cảnh.

(iii) **Bài học kinh nghiệm:** Nhóm nhận ra rằng sự đa dạng của dữ liệu đầu vào có giá trị quyết định hơn số lượng tầng của mạng. Một cấu trúc CNN tinh gọn nhưng được huấn luyện trên dữ liệu sạch và đa dạng vẫn cho hiệu quả thực tế cao hơn các mạng quá sâu nhưng thiếu tính tổng quát.

2. Hướng phát triển

2.1. Hoàn thiện chức năng và nhiệm vụ hiện tại

- **Tối ưu hóa siêu tham số:** Tích hợp các thuật toán tối ưu như **Adam** hoặc **RMSprop** với cơ chế tự động giảm tốc độ học (Learning Rate Scheduler) khi hàm mất mát đi vào vùng bão hòa.
- **Mở rộng danh mục cây trồng:** Bổ sung thêm dữ liệu của các loại cây công nghiệp và cây ăn quả khác để mô hình trở thành một bộ từ điển bệnh lý cây trồng toàn diện.
- **Cải thiện độ phân giải:** Nâng cấp khả năng xử lý ảnh đầu vào có độ phân giải cao hơn mà không làm tăng quá mức chi phí tính toán thông qua kỹ thuật **Depthwise Separable Convolution**.

2.2. Nâng cấp và phát triển các hướng đi mới

- **Triển khai trên thiết bị di động:** Chuyển đổi mô hình sang định dạng **TensorFlow Lite** để đóng gói thành ứng dụng di động, giúp nông dân có thể quét lá bệnh trực tiếp tại đồng ruộng mà không cần kết nối internet.
- **Kết hợp dữ liệu ngoại biên:** Tích hợp thêm các biến định lượng như nhiệt độ, độ ẩm từ cảm biến IoT để tăng độ chính xác cho việc dự báo khả năng bùng phát dịch bệnh.

- **Hệ thống khuyến nghị:** Không chỉ dừng lại ở phân loại, hệ thống sẽ tự động đưa ra các giải pháp sinh học hoặc thuốc bảo vệ thực vật phù hợp dựa trên loại bệnh đã nhận diện được.

IV. Tài liệu tham khảo

1. <https://viblo.asia/p/gioi-thieu-ve-deep-learning-deep-learning-hoat-dong-nhu-the-nao-3Q75w2nDIWb>
2. <https://vnptai.io/vi/blog/detail/neural-network-la-gi>
3. <https://vnptai.io/vi/blog/detail/convolutional-neural-networks-la-gi>
4. <https://www.youtube.com/watch?v=UIPmxeyRWdA>
5. https://www.youtube.com/watch?v=sWPNm_GhhCA